Сколько букв достаточно?

Минимальное начало, различающее корневое семейство. Модельная оценка, а не перепись всего русского языка.

5,72

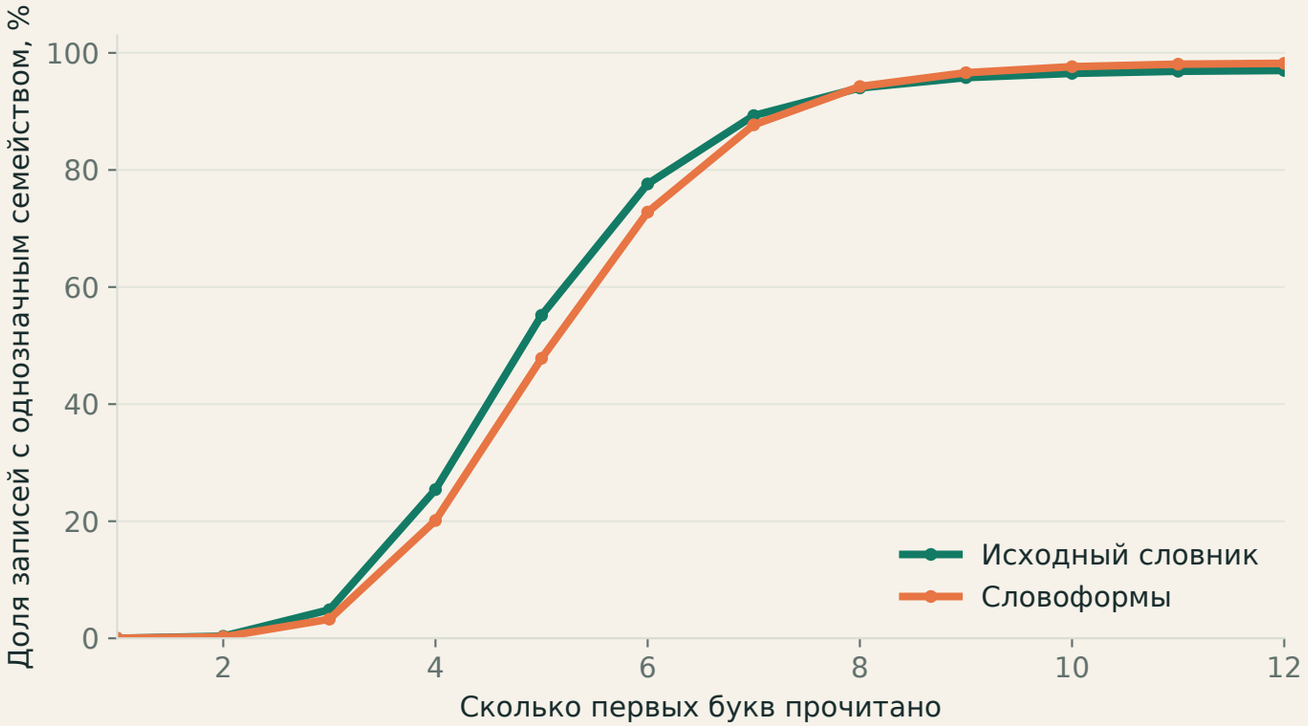
буквы в среднем · словоформы

95 893

исходных написаний

14 302

группы в основной модели



5 букв

различают 55,2% исходных записей; после 7 букв — 89,3%.

Корень ≠ ответ

Иногда хватает части корня. Иногда нужны приставка, суффикс или сигнал конца слова.

Обработано 1 778 766 различных написаний словоформ. Средние длины посчитаны только там, где различающее начало существует. Все проценты — от всех записей соответствующего набора. Семейства определены алгоритмически; у части корней нет надёжного омонимического ID.

Твои примеры — и точное правило

Двигаемся слева направо. Останавливаемся, когда все словарные продолжения принадлежат одному семейству.

к р а с → **к р а с н** **5 букв**

«крас» ещё допускает «красивый» и «краска». В принятой модели «красн» уже выделяет семейство красного. Красная, красные и красный дают один результат.

м р а → **м р а ч** **4 буквы**

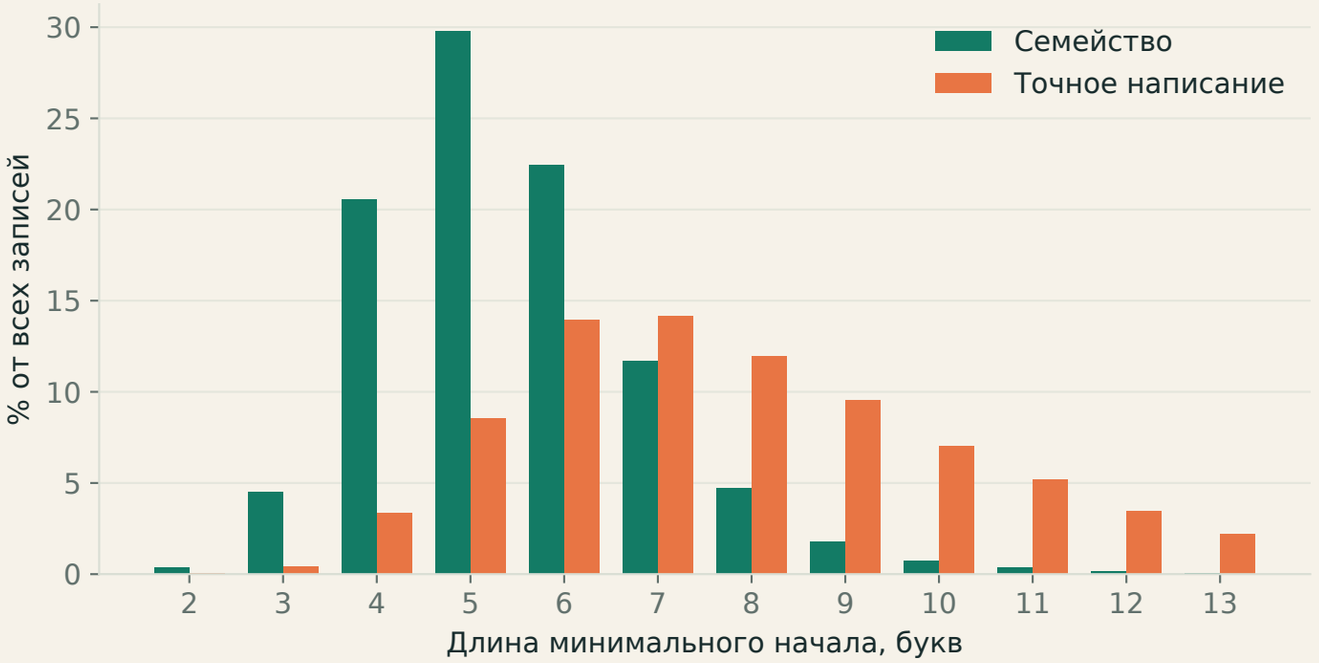
«мра» допускает «мрамор» и «мразь». «мрач» различает мрачность, мрачный и мрачнеть. Варианты «мрак/мрач» связаны по словарю чередований.

Слово / формы	Минимальное начало	Сегмент / длина слова
красный / красная / красные	красн	5 / 7, 7, 7
мрачность / мрачный / мрачнеть	мрач	4 / 9, 7, 8
кот	нет без конца слова	3 буквы целого слова

Важно: минимальность зависит от словаря. Если убрать «красивый» и все остальные крас-конкуренты, потребуется меньше букв. Это задача о словарных продолжениях, а не измерение того, как человек угадывает слово из контекста.

Начало информативнее окончания

Одинаковые веса у записей словаря; частотность реальной речи здесь не используется.



5,45

буквы → семейство

8,02

буквы → точное написание

8,10

буквы с конца → семейство

Медиана различающего начала — 5 букв; 90-й процентиль среди разрешимых записей — 7. Средняя полная дли
— 10,23 буквы. В разрешимых случаях в среднем остаются непрочитанными 4,92 буквы.

Сравнение средних условное: у каждого режима собственный набор разрешимых записей. У точного написания больше случаев, когда нужен сигнал окончания. Сравнение показывает свойства этих словарей, а не универсальное преимущество чтения слева направо.

Граница корня редко является оптимальной

Сопоставление минимального начала с морфемным разбором исходной записи. Только слова с одним размеченным корнем и найденным ответом.



31,9% Остановиться до конца корня

17,0% Сегмент в точности равен корню

18,0% Приставка + целый корень

33,1% Прочитать дальше корня

Равенство «минимальное начало = корень» возможно только у слова без приставки. У приставочного слова можно дойти до правой границы корня, но прочитанный сегмент включает и приставку.

Случаи без ответа (2 788) и неоднозначные/многокоренные разборы (18 107) не включены в круг. Если заранее дать границу самого корня, отдельный эксперимент на корневых вариантах даёт среднее 4,93 буквы среди разрешимых вариантов; это другая выборка и другая задача.

Словоформы: почти 1,8 миллиона проверок

Формы порождены только из известных словарных разборов pymorphy3 / OpenCorpora. Неизвестные слова нейросетью не достраивались.

1 778 766

уникальных написаний форм

5,72

буквы · разрешимые записи

98,38%

разрешимы по началу

Неоднозначность бывает двух видов

1. Нужно знать, что слово закончилось: 10 406 записей. Например, после «мама» ещё возможна «мамалыга». Пробел разрешает эту неоднозначность.

2. Совпало полное написание разных групп: 18 481 записей. Ни следующая буква, ни пробел не помогут: нужен контекст или исправление ошибочной группировки.

Для развёртки нашлось 78 288 исходных словарных лемм. Формы остальных записей не гарантируются. Нормализация пересопоставила 2 657 исходных написаний; у 10 289 не найдено известной нормальной формы внутри исходного набора.

Среднее по словоформам сильнее взвешивает слова с большими парадигмами. Поэтому сдвиг среднего относительно исходного словника нельзя целиком приписать добавлению конкурентов. Это не частотность речи.

Число семейств зависит от определения

Единственного автоматического разбиения на «всё однокоренное» нет: составное слово может относиться сразу к нескольким корням.

Модель	Написаний	Групп	Среднее*	Разрешимо
Основная: первый корень + IDs + формы	95 893	14 302	5,45	97,1%
Только написание первого корня	95 893	14 784	5,39	98,5%
Все корни как упорядоченный набор	95 893	27 949	5,99	97,5%
Гнёзда Тихонова, пересечение	36 201	1 555	5,35	72,3%
Большая сеть DeriNet.RU, фильтр	214 966	111 299	8,08	81,2%

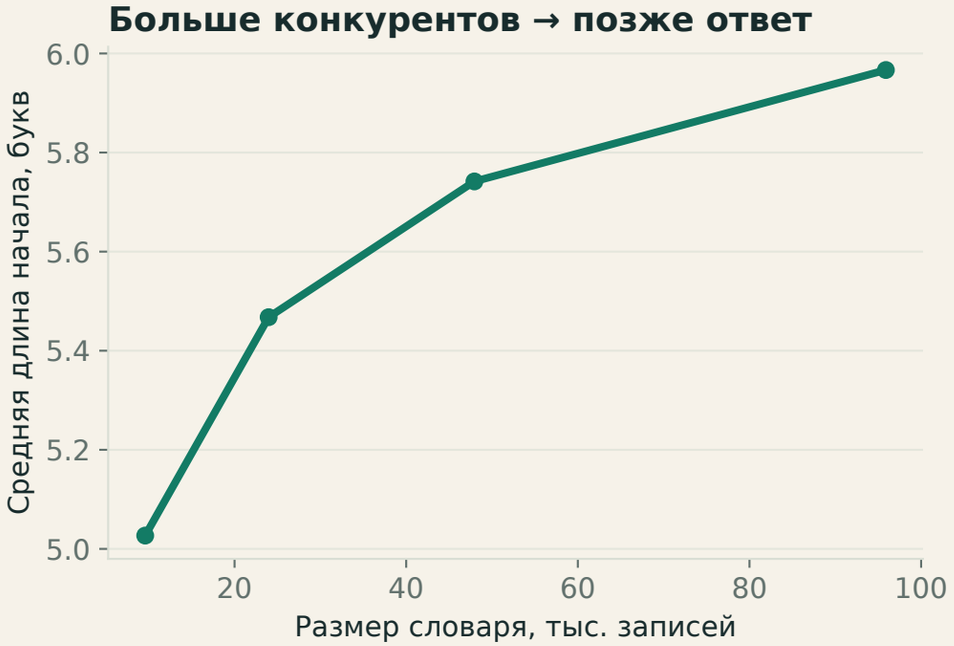
Лесовоз связан с лесом и с возить. Если транзитивно склеивать все слова, у которых есть хотя бы один общий корень, через такие мостики возникают большие семантически разнородные компоненты. Основной расчёт поэтому выбирает первый корень; альтернативный сохраняет весь набор.

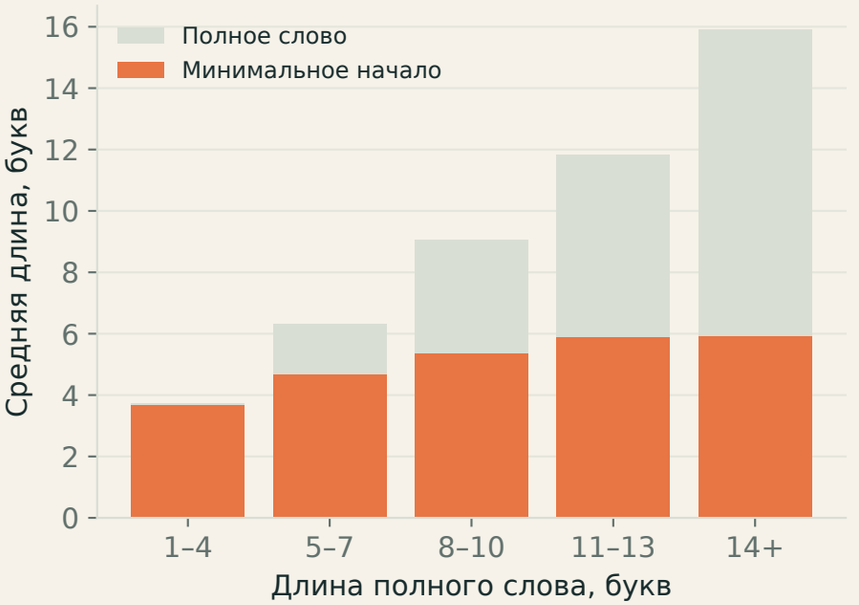
DeriNet.RU: 337 632 исходные записи; убраны 113 919 записей с заглавными буквами, затем схлопнуты повторы. Фильтр не убирает все имена, опечатки и ошибки лемматизации. Гнёзда — неполный набор преимущественно продуктивных семейств, а не уменьшенная перепись языка.

* Все средние только по разрешимым записям. Эти модели различаются и словником, и качеством связей; разницу нельзя трактовать как доверительный интервал.

Ещё три наблюдения

Размер словаря, длина слова и перегруженные начала меняют порог различимости.





Слева: фиксированные 2 000 целевых записей и вложенные случайные словари (seed 1648); модель — полный набор поверхностных корней. Неразрешимых целей: от 26 до 55. Изменение среднего не заменяет проверку каждой отдельной записи.

Где дольше всего тесно

пере
631 групп

пред
158 групп

анти
109 групп

прос
103 групп

Количество разных семейств среди продолжений данного четырёхбуквенного начала в основном словнике. Это не частота употребления.

Что доказано — и где граница точности

Алгоритм точно решает задачу для заданного словника и заданных меток. Лингвистическая истинность самих меток не гарантируется.

Воспроизводимость

Дерево продолжений проверено полным перебором на случайных словарях. Для 1,8 млн форм используется независимый алгоритм на сортировке: он сверяется с деревом. Для каждой записи сохранён конкурент, подтверждающий невозможность остановиться раньше.

Главные ограничения

Нет замкнутого списка всех современных русских слов. Основа морфемного набора — словарь Тихонова; свежие термины покрыты неполно. У 45 486 исходных разборов при построении модели нет разрешённого ID варианта: метка R — техническое объединение по написанию первого корня, а не доказанная общность происхождения. Метки K используют Кузнецову: они местами этимологические и могут объединять уже разошедшиеся современные семьи.

Ё приравнена к е, ударения сняты, регистр приведён к нижнему. Дефис участвует в различении, но не считается буквой. Числа взвешены по записям (написание, семейство), а не по словам в живой речи. Две явно указанные словарные записи добавлены к размеченному релизу: красный и мрачность. Уверенность человека и распознавание в контексте не измерялись.

Источники

RuMorphs-Lemmas / морфемы · https://cmc-msu-ai.github.io/NLPDatasets/

Кузнецова / корни и чередования · https://github.com/tabidots/ru_roots

Тихонов / оцифрованные гнёзда · https://github.com/mashashaitz/Russian-Derinet

DeriNet.RU / UDer v1.1 · https://hdl.handle.net/11234/1-3247

pymorphy3 / словари OpenCorpora · https://pypi.org/project/pymorphy3/